



UNIVERSIDADE FEDERAL RURAL DE PERNAMBUCO
CURSO DE BACHARELADO EM SISTEMAS DE INFORMAÇÃO
CAMPUS SEDE-RECIFE

**Análise Epidemiológica das Arboviroses em Pernambuco no período de
02/01/2000 a 14/06/2026**

Edniz Leandro da Silva

RECIFE 2026

Resumo

As arboviroses, especialmente dengue, zika e chikungunya, representam um dos maiores desafios para a saúde pública brasileira devido à elevada incidência de casos, recorrência de epidemias e impactos sociais, económicos e ambientais. Embora o Sistema de Informação de Agravos de Notificação (SINAN) disponibilize uma das maiores bases epidemiológicas do mundo, sua utilização em pesquisas científicas é dificultada pela heterogeneidade estrutural das bases históricas, pela existência de diferentes versões das fichas de notificação e pelo elevado volume de registros produzidos ao longo dos anos. Este trabalho apresenta o desenvolvimento de um pipeline de engenharia de dados de alto desempenho capaz de integrar, validar, padronizar e analisar notificações de arboviroses registradas no estado de Pernambuco entre os anos de 2000 e 2026. A solução proposta combina as tecnologias Python e Apache Parquet para processar mais de 1,299,000 notificações epidemiológicas distribuídas em diferentes estruturas históricas do SINAN. Diferentemente dos processos tradicionais de ETL (Extract, Transform and Load), o pipeline realiza automaticamente a harmonização dos esquemas das bases históricas, validação epidemiológica, auditoria da qualidade dos dados, geração de inventário das variáveis e armazenamento otimizado para consultas analíticas. Os experimentos demonstram elevada escalabilidade, redução significativa do consumo de memória e maior velocidade de processamento, mantendo a consistência epidemiológica dos dados. A arquitetura desenvolvida constitui uma solução aberta, modular e reproduzível, podendo apoiar pesquisas científicas, vigilância epidemiológica, modelagem preditiva e sistemas inteligentes de apoio à decisão em saúde pública.

Palavras-chave: Engenharia de Dados; Epidemiologia; Arboviroses; Dengue; Zika; Chikungunya; Apache Parquet; Python.

1. Introdução

As arboviroses transmitidas pelo mosquito *Aedes aegypti* constituem um dos principais problemas de saúde pública em países tropicais e subtropicais. Entre essas doenças destacam-se a dengue, a zika e a chikungunya, responsáveis por milhões de notificações anuais, elevada demanda pelos serviços de saúde e importantes impactos económicos.

No Brasil, o acompanhamento epidemiológico dessas doenças é realizado por meio do Sistema de Informação de Agravos de Notificação (SINAN), administrado pelo Ministério da Saúde. O sistema armazena registros provenientes de milhares de unidades de saúde distribuídas em todo o território nacional, constituindo uma das maiores bases públicas de vigilância epidemiológica existentes. Apesar de sua importância científica, o uso dessas bases apresenta diversos desafios computacionais. Ao longo dos últimos vinte anos, ocorreram sucessivas alterações nas fichas de notificação, modificando nomes de variáveis, códigos de classificação, critérios diagnósticos e campos obrigatórios. Essas mudanças tornam incompatíveis diferentes versões históricas do banco de dados, dificultando sua integração em análises de longa duração. Além disso, o elevado volume de registros representa outro obstáculo. Bases contendo dezenas de milhões de notificações tornam inviável a utilização de ferramentas tradicionais, como planilhas eletrônicas ou bancos de dados convencionais, principalmente em computadores pessoais. Ademais, a modelagem da dispersão espacial e temporal das arboviroses por meio de abordagens baseadas em sistemas complexos, como os Autômatos Celulares (AC), exige dados de entrada com alto

rigor de consistência e resolução geográfica. Modelos de AC dependem diretamente da precisão das condições iniciais e do histórico epidêmico para a calibração de suas regras de transição locais. Portanto, a fragmentação estrutural do SINAN atua como um gargalo limitante não apenas para análises estatísticas tradicionais, mas primordialmente para o desenvolvimento de simulações preditivas que mimetizam a dinâmica de contágio em grades celulares.

Diante desse cenário, ferramentas convencionais como planilhas eletrônicas frequentemente apresentam limitações de desempenho quando utilizadas nesse contexto (MCKINNEY, 2022). Para superar esses obstáculos, este trabalho apresenta o desenvolvimento de um pipeline automatizado de engenharia de dados voltado especificamente para as bases históricas de arboviroses do estado de Pernambuco entre os anos de 2000 e 2026.

2. Motivação

Grande parte dos estudos epidemiológicos concentra seus esforços na análise estatística dos dados, dedicando pouca atenção à etapa de preparação das bases utilizadas. Entretanto, em bancos históricos de grande porte, essa etapa representa um dos maiores desafios da pesquisa científica. Durante o desenvolvimento deste projeto foram identificadas três limitações principais. A primeira refere-se à heterogeneidade estrutural das bases históricas do SINAN. Cada período possui layouts diferentes, variáveis exclusivas, alterações de nomenclatura e mudanças nas codificações utilizadas pelo Ministério da Saúde. A segunda limitação está relacionada à qualidade dos dados. Foram observadas inconsistências temporais, elevada quantidade de valores ausentes, mudanças de categorias, duplicidades e diferenças entre os códigos utilizados em versões distintas das fichas de investigação. A terceira limitação corresponde ao desempenho computacional. O processamento de dezenas de milhões de registros utilizando ferramentas tradicionais demanda grande quantidade de memória RAM e tempo elevado de execução. Esses problemas motivaram o desenvolvimento de uma arquitetura especializada em engenharia de dados epidemiológicos, capaz de automatizar todas as etapas de integração, limpeza, validação e preparação das bases para análises científicas. A implementação foi realizada integralmente na linguagem Python devido à sua ampla utilização em ciência de dados, elevada disponibilidade de bibliotecas especializadas e capacidade de integração com diferentes tecnologias de processamento analítico (MCKINNEY, 2022).

3. Arquitetura Proposta

A arquitetura desenvolvida foi estruturada segundo princípios de modularidade, escalabilidade e reprodutibilidade científica. O sistema foi dividido em seis camadas independentes. A primeira camada é responsável pela ingestão automática dos arquivos originais do SINAN em formato CSV. Na segunda camada ocorre a identificação automática das diferenças existentes entre os layouts históricos, permitindo que variáveis equivalentes sejam harmonizadas em um esquema padronizado. A terceira camada realiza a validação epidemiológica dos registros, verificando consistência temporal, padronização dos códigos municipais, categorias válidas, duplicidades e qualidade dos dados. Na quarta camada os dados são convertidos para o formato Apache Parquet, que utiliza armazenamento colunar altamente eficiente. A quinta camada gerar automaticamente relatórios epidemiológicos,

inventários das variáveis, indicadores estatísticos e dashboards interativos destinados ao apoio à tomada de decisão (local). Finalmente, sexto foi a escolha da plataforma Streamlit para as visualizações dos dados. Essa organização reduz o acoplamento entre componentes, facilita a manutenção do software e permite sua adaptação para outros agravos de notificação compulsória sem necessidade de modificações significativas na lógica de processamento (PRESSMAN; MAXIM, 2020).

4. Pipeline de Engenharia de Dados

O pipeline desenvolvido automatiza todas as etapas necessárias para transformar arquivos brutos do SINAN em bases científicas prontas para análise. Inicialmente, todos os arquivos históricos são identificados automaticamente e carregados pelo sistema. Em seguida, é realizada uma inspeção estrutural para identificar quais variáveis estão presentes em cada período histórico. Em vez de assumir que todas as bases possuem o mesmo layout, O pipeline constrói dinamicamente um esquema unificado utilizando um dicionário de variáveis canônicas. Quando determinada variável não está presente em um período específico, ela é criada automaticamente utilizando valores nulos, preservando a compatibilidade estrutural entre todas as bases. Após essa harmonização, o sistema executa rotinas automáticas de validação, incluindo:

- Verificação de valores ausentes;
- Detecção de duplicidades;
- Validação temporal das datas;
- Padronização de municípios;
- Verificação das categorias epidemiológicas;
- Análise da completude das variáveis;
- Auditoria da qualidade dos dados.

Posteriormente, as bases são convertidas para o formato Apache Parquet, reduzindo significativamente o espaço de armazenamento e aumentando o desempenho das consultas. Por fim, criam-se visualizações analíticas diretamente sobre o arquivo Parquet, permitindo executar consultas envolvendo dezenas de milhões de registros sem necessidade de carregar integralmente os dados na memória. Em comparação com arquivos CSV, esse formato proporciona maior taxa de compressão, redução do espaço ocupado em disco e leitura seletiva apenas das colunas necessárias à consulta, melhorando significativamente o desempenho computacional (APACHE SOFTWARE FOUNDATION, 2025).

5. Relevância Científica

O principal diferencial do software desenvolvido está na automatização completa do processo de engenharia de dados epidemiológicos. Enquanto abordagens convencionais limitam-se à concatenação de arquivos ou à execução de rotinas simples de limpeza, a solução proposta realiza a integração inteligente de bases heterogêneas, preservando a consistência histórica das informações. Entre as principais contribuições destacam-se:

- Integração automática de bases históricas do SINAN;
- Harmonização de aproximadamente 197 variáveis epidemiológicas;
- Validação automática da qualidade dos dados;
- Detecção de inconsistências estruturais;

- Geração automática de inventário das variáveis;
- Produção de relatórios epidemiológicos;
- Armazenamento otimizado no formato colunar;
- Arquitetura modular e totalmente reprodutível.

Essas funcionalidades transformam bases brutas de notificação em conjuntos de dados prontos para pesquisas científicas, modelagem estatística, aprendizado de máquina, sistemas inteligentes e vigilância epidemiológica. A automatização das etapas de integração e validação reduziu significativamente o esforço necessário para preparação dos dados, etapa frequentemente considerada uma das mais complexas em estudos baseados em grandes bases secundárias (WICKHAM; GROLEMUND, 2017).

6. Avaliação de Desempenho

Esse pipeline foi aplicado às notificações históricas de arboviroses do estado de Pernambuco compreendendo o período de 2000 a 2026. A utilização do formato Apache Parquet proporcionou uma redução significativa no espaço ocupado pelos dados, além de melhorar o desempenho das operações de leitura. Os resultados experimentais obtidos demonstram que a arquitetura proposta apresenta elevada escalabilidade, sendo perfeitamente adequada para manipular grandes volumes de dados epidemiológicos em computadores pessoais convencionais, resultando num ganho expressivo de velocidade operacional e otimização de memória RAM. Do ponto de vista da modelagem computacional, a otimização do tempo de processamento obtida pelo pipeline viabiliza a execução de simulações de Autômatos Celulares em larga escala. Como esses algoritmos operam em iterações massivas sobre matrizes espaciais, a capacidade de extrair estados históricos padronizados e alimentar o modelo em tempo real reduz drasticamente o custo computacional total, permitindo simular frentes de expansão da dengue e zika bairro a bairro com alta fidelidade.

7. Impacto Científico

O pipeline desenvolvido possui potencial para apoiar diversas áreas da pesquisa científica e da gestão em saúde pública. Pesquisadores podem utilizar a infraestrutura proposta para realizar análises temporais, espaciais e estatísticas envolvendo dengue, zika e chikungunya. Entre as aplicações possíveis destacam-se:

- Estudos de séries temporais;
- Análise espacial da disseminação das doenças;
- Construção de mapas epidemiológicos;
- Mineração de dados em saúde;
- Aprendizado de máquina;
- Modelos preditivos de surtos;
- Sistemas de apoio à decisão;
- Dashboards epidemiológicos interativos no streamlit;
- Integração com dados climáticos e socioeconômicos.

8. Conclusão

Este trabalho apresentou o desenvolvimento de um pipeline de engenharia de dados destinado à integração e análise de bases históricas de arboviroses do estado de

Pernambuco. A solução proposta foi capaz de integrar automaticamente diferentes versões do SINAN, harmonizando estruturas distintas, validando a qualidade dos dados e produzindo uma base analítica consolidada contendo mais de 1,299,000 notificações epidemiológicas. A combinação das tecnologias Python, Apache Parquet que proporcionou elevado desempenho computacional reduzindo o consumo de memória e permitindo consultas analíticas eficientes sobre grandes volumes de dados utilizando a plataforma streamlit para visualização dos dados.

Como perspectivas futuras, propõe-se a integração dessa base analítica consolidada a modelos dinâmicos baseados em Autômatos Celulares, utilizando as notificações históricas purificadas para definir as probabilidades de transição de estado das células (vulnerável, infectado, recuperado). Dessa forma, a arquitetura desenvolvida estabelecendo-se como a infraestrutura de suporte indispensável para simulações complexas de espalhamento epidêmico e apoio preditivo à tomada de decisão em saúde pública. Assim, a crescente digitalização dos sistemas de informação em saúde tem proporcionado uma expansão significativa da quantidade de dados disponíveis para pesquisas epidemiológicas. Esses dados representam um importante recurso para monitoramento de doenças, avaliação de políticas públicas e desenvolvimento de modelos preditivos capazes de apoiar a vigilância em saúde (WORLD HEALTH ORGANIZATION, 2024).

9. Referências

APACHE SOFTWARE FOUNDATION. Apache Parquet Documentation. Disponível em: <https://parquet.apache.org/>

BRASIL. Ministério da Saúde. Sistema de Informação de Agravos de Notificação (SINAN): normas e rotinas. Brasília: Ministério da Saúde, 2024.

BRASIL. Ministério da Saúde. Guia de Vigilância em Saúde. 6. ed. Brasília: Ministério da Saúde, 2024.

HARRISON, Matt. Effective Pandas: Patterns for Data Manipulation. Seattle: MetaSnake, 2021.

MCKINNEY, Wes. Python for Data Analysis. 3. ed. Sebastopol: O'Reilly Media, 2022.

PEDREGOSA, F. et al. Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, v. 12, p. 2825–2830, 2011.

PRESSMAN, Roger S.; MAXIM, Bruce R. Engenharia de Software: uma abordagem profissional. 9. ed. Porto Alegre: AMGH, 2020.

STREAMLIT INC. Streamlit Documentation. Disponível em: <https://docs.streamlit.io/>.

VAN ROSSUM, Guido; DRAKE, Fred L. The Python Language Reference. Python Software Foundation. Disponível em: <https://www.python.org>.

WICKHAM, Hadley; GROLEMUND, Garrett. R for Data Science. Sebastopol: O'Reilly Media, 2017.

WORLD HEALTH ORGANIZATION. Global strategy for dengue prevention and control. Geneva: WHO, 2024.

WORLD HEALTH ORGANIZATION. Vector-borne diseases. Geneva: WHO, 2024. Disponível em: <https://www.who.int/news-room/fact-sheets/detail/vector-borne-diseases>